

DST Airlines

Membre de l'équipe

Nicolas CALO
Johan CLOOS
Younes Es-soualhi
Rathana LAT
Youssef ZNATI

Étape 3 - Consommation de la donnée

Description

Objectif

- Ici, le but principal du projet sera de faire un algorithme de prévision de retard des avions grâce aux données que vous avez précédemment stockées dans vos Bases de données

Modules / Masterclass / Templates

- DE120

Conditions de validation du projet

- Algorithme de Machine Learning

Etude des données tabulaires

Contexte

Dans le cadre du projet de prédiction des retards de vols, les données issues de l'API Air France-KLM ont été collectées au format JSON, transformées en CSV puis analysées.

L'objectif de cette étape est de :

- Identifier les champs réellement exploitables pour l'entraînement du modèle prédictif
- Mesurer la proportion de valeurs manquantes dans chaque variable
- Déterminer quelles variables doivent être conservées, ignorées ou réservées pour de l'analyse descriptive

Structuration des données

Les variables ont été réparties en quatre catégories selon leur rôle dans la modélisation :

- Variables directement utilisées par le modèle pour apprendre à prédire le retard (explicatives)
- Variables complémentaires servant à interpréter ou illustrer les résultats (descriptives)
- Variable à prédire, représentant l'état final du vol (cible)
- Variables exclues du jeu d'apprentissage pour cause de redondance, d'inutilité ou de complétude insuffisante (non retenues)

Variables explicatives

Champ	Taux de valeurs manquantes
flightLegs-status	16.99
flightLegs-scheduledFlightDuration	8.37
flightLegs-aircraft-ownerAirlineCode	6.04
flightLegs-serviceType	0.0
flightLegs-aircraft-typeCode	0.0
flightLegs-departureInformation-times-scheduled	0.0

flightLegs-arrivalInformation-times-scheduled	0.0
flightLegs-departureInformation-airport-code	0.0
flightLegs-arrivalInformation-airport-code	0.0
flightLegs-departureInformation-airport-city-country-code	0.0
flightLegs-arrivalInformation-airport-city-country-code	0.0
flightLegs-departureInformation-airport-city-country-areaCode	0.0
flightLegs-arrivalInformation-airport-city-country-areaCode	0.0
flightLegs-departureInformation-airport-location-latitude	0.0
flightLegs-departureInformation-airport-location-longitude	0.0
flightLegs-arrivalInformation-airport-location-latitude	0.0
flightLegs-arrivalInformation-airport-location-longitude	0.0
flightNumber	0.0

Variables descriptives

Champ	Taux de valeurs manquantes
flightLegs-irregularity-delayInformation-delayReasonPublicLong	88.73
flightLegs-irregularity-delayInformation-delayReasonPublicShort	88.73
flightLegs-departureInformation-airport-places-departurePositionTerminal-boardingTerminal	70.93
flightLegs-arrivalInformation-airport-places-arrivalPositionTerminal	59.42
flightLegs-departureInformation-airport-places-departurePositionTerminal-gateNumber	46.89
flightLegs-arrivalInformation-airport-city-country-name	0.0
flightLegs-departureInformation-airport-city-country-name	0.0

Variable cible

Champ	Taux de valeurs manquantes
FlightStatusPublic	0.0
flightLegs-irregularity-delayDuration	74.01

Variables non retenues

Champ	Taux de valeurs manquantes
flightLegs-irregularity-delayReason	100.0
flightLegs-departureInformation-times-actualTakeOffTime	43.11
flightLegs-departureInformation-times-actual	42.96
flightLegs-arrivalInformation-times-actual	39.06
flightLegs-arrivalInformation-times-actualTouchDownTime	38.96
flightLegs-arrivalInformation-times-latestPublished	0.27
flightLegs-arrivalInformation-times-estimated-value	0.27
flightLegs-departureInformation-times-latestPublished	0.26

Analyse des catégories

flightStatusPublic

flightStatusPublic	Taux
ARRIVED	0.909618
ON_TIME	0.063893
CANCELLED	0.022626
PARTIALLY_CANCELLED	0.003707

DELAYED_DEPARTURE	0.000142
DEPARTED	0.000007
NEW_DEPARTURE_TIME	0.000007

flightLegs-serviceType

Type	Correspondance du type	Taux
J	Normal Service	0.947830
U	Service operated by Surface Vehicle	0.043422
C	Passenger Only	0.005516
G	Normal Service	0.003185
S	Shuttle Mode	0.000020
L	Passenger and Cargo/ Mail	0.000020
O	Migrants/ Immigrants	0.000007

flightLegs-status

Statut	Libellé du statut	Taux
S	Scheduled	0.928392
C	Cancelled	0.070408
N	New	0.000653
G	Ground return	0.000237
T	Return to Ramp	0.000220
A	Air return	0.000049
R	Return from Airborn	0.000041

Exploration des données

Contexte

L'exploration des données a pour but de nettoyer et préparer le jeu de données, c'est-à-dire d'enlever les champs ou valeurs non pertinents pour la modélisation et d'identifier les vols réellement en retard ou anormaux. Le jeu de données étudié est issu d'un export CSV de plus de 700 000 enregistrements.

Analyse de la variable `flightStatusPublic`

<code>flightStatusPublic</code>	Taux (%)
ARRIVED	91,2516
ON_TIME	5,5515
CANCELLED	3,0631
PARTIALLY_CANCELLED	0,1323
DELAYED_DEPARTURE	0,0013
DEPARTED	0,0001
NEW_DEPARTURE_TIME	0,0001

Cette variable décrit l'état global d'un vol. La majorité des enregistrements concernent des vols arrivés (91,25 %), suivis des vols à l'heure (5,55 %) et annulés (3,06 %).

Les catégories `DEPARTED` et `NEW_DEPARTURE_TIME` sont considérées comme des valeurs extrêmes et incomplètes :

- `DEPARTED` correspond à un vol parti sans qu'un statut d'arrivée ait été renseigné
- `NEW_DEPARTURE_TIME` désigne une donnée administrative liée à la replanification des horaires

Ces deux catégories doivent être supprimées du jeu d'entraînement afin de ne pas perturber le modèle prédictif.

Analyse de la variable flightLegs_serviceType

Type	Correspondance du type	Taux
J	Normal Service (vol programmé)	98,6143
U	Service operated by Surface Vehicle	0,7257
C	Passenger Only	0,3500
G	Normal Service (vol non planifié)	0,2948
S	Shuttle Mode	0,0121
O	Migrants/ Immigrants	0,0025
L	Passenger and Cargo/ Mail	0,0005

Cette variable décrit le type d'opération du vol. La grande majorité des vols sont de type J (Normal Service) avec 98,61 %.

Le type G correspond à des vols additionnels non prévus dans le plan initial. Bien que le libellé soit identique à J, leur occurrence est très faible (0,29%). Leur similarité opérationnelle justifiera leur fusion afin de simplifier le modèle de prédiction.

Les types L et O, correspondant respectivement à Passenger & Cargo/Mail et Migrant/Immigrant, devront être supprimés. Ces catégories sont trop rares pour être significatives et doivent être écartées du jeu d'entraînement.

Analyse de la variable flightLegs_status

Statut	Libellé du statut	Taux
S	Scheduled	92,2567
C	Cancelled	7,6491
N	New	0,0474
T	Return to Ramp	0,0236
G	Ground return	0,0120
R	Return from Airborn	0,0079
A	Air return	0,0033

Cette variable décrit l'état du vol au niveau opérationnel. Les valeurs principales sont S pour les vols planifiés (92,25%) et C pour les vols annulés 7,65%).

Les valeurs N (New), G (Ground Return), T (Return to Ramp), A (Air Return) et R (Return from Airborne) représentent des cas particuliers liés à des anomalies ou retours d'urgence.

Le statut N étant un statut prévisionnel non validé, il est supprimé.

Les autres valeurs rares mais opérationnellement significatives sont conservées pour détecter des comportements anormaux lors de l'apprentissage.

Synthèse des irrégularités par flightStatusPublic

flightStatusPublic	Total vols	Vols avec irrégularité	% d'irrégularités
ARRIVED	694815	182386	26,25
CANCELLED	23323	1295	5,55
ON_TIME	42271	452	1,07
PARTIALLY_CANCELLED	1007	25	2,48
DELAYED_DEPARTURE	10	4	40
DEPARTED	1	0	0
NEW_DEPARTURE_TIME	1	0	0

Synthèse des irrégularités par flightLegs_status

flightLegs_status	Total vols	Vols avec irrégularité	% d'irrégularités
S	582540	182613	31,35
C	48299	1480	3,06
T	149	49	32,89
R	50	11	22
N	299	6	2,01
G	76	3	3,95
A	21	0	0

Synthèse des irrégularités par flightLegs_serviceType

flightLegs_serviceType	Total vols	Vols avec irrégularité	% d'irrégularités
J	750877	183375	24,42
G	2245	608	27,08
C	2665	129	4,84
U	5526	50	0,90
L	4	0	0
O	19	0	0
S	92	0	0

Top 10 des flightLegs_aircraft_ownerAirlineCode par taux d'irrégularités

ownerAirlineCode	Total vols	Vols avec irrégularité	% d'irrégularités
R6	2	2	100
T3	3314	2846	85,88
ZQ	6846	5406	78,97
KL	50755	38849	76,54
WA	46806	35256	75,32
ED	4	3	75
AF	75895	56531	74,49
JP	9	6	66,67
A5	20981	13808	65,81
XK	8018	4983	62,15

Top 10 des flightLegs_aircraft_typeCode par taux d'irrégularités

typeCode	Total vols	Vols avec irrégularité	% d'irrégularités
295	14496	12368	85,32
73J	4106	3078	74,96
318	4150	2810	67,71
E90	55593	31747	57,11
772	5945	3317	55,79
E70	7112	3835	53,92
223	36574	18750	51,27
77W	8359	4012	48
73W	9060	3920	43,27
E7W	25113	9973	39,71

L'exploration des données a permis :

- De supprimer ou fusionner les valeurs extrêmes et incohérentes
- D'identifier les variables explicatives fiables pour le modèle prédictif

Pipeline de Machine Learning avec SciKit-learn

Objectif

- Depuis les données obtenues par l'API Air France - KLM, Prédire l'occurrence de retard/annulation et sa durée le cas échéant sur les vols prévus en se basant sur les vols historiques

Jeu de données

- Toutes les données obtenues par le biais de l'API jusqu'au 2025-11-06

Sélection des données

- Filtrage des données pour ne garder que les vols partant ou arrivant dans un des aéroports du Top 30 européen en termes de nombre de vols journaliers
- Vols uniquement entre aéroports européens (code IATA)

492435 vols conservés

Feature engineering

- flightLegs_scheduledFlightDuration = flightLegs_arrivalInformation_times_scheduled - flightLegs_departureInformation_times_scheduled
- flightLegs_Category
 - 'late' si 'flightLegs_irregularity_delayDuration_total' >0
 - 'cancelled' si flightLegs_legStatusPublic = 'CANCELLED'
 - Sinon 'on_time'
- Saisonnalité
 - Décembre - Février -> Hiver
 - Mars - Mai -> Printemps
 - Juin - Août -> Été
 - Septembre - Novembre -> Automne
- Période journalière (pour arrivée/destination séparément)
 - 00:00:00 - 05:59:59 -> Nuit
 - 00:60:00 - 11:59:59 -> Matin
 - 00:12:00 - 17:59:59 -> Après-midi
 - 00:18:00 - 23:59:59 -> Soir
- Weekend (Samedi/Dimanche) (pour arrivée/destination séparément)

Feature preprocessing

- Données numériques
 - Pipeline([('imputer', SimpleImputer(strategy='median')), ('scaler', StandardScaler())])
- Données catégorielles
 - Pipeline([('imputer', SimpleImputer(strategy='most_frequent'))])
- One-hot encoding
 - ('onehot', OneHotEncoder(handle_unknown='ignore', drop='first', sparse_output=True))])

Classification

Séparation jeux de données

- entraînement 80% 393948 vols
- test 20% 98487 vols

Type de données

- Valeur cible : flightLegs_Category
 - on_time
 - late
 - cancelled
- Valeurs explicatives
 - Catégorielles
 - 'flightLegs_aircraft_typeCode'
 - 'flightLegs_arrivalInformation_airport_code'
 - 'flightLegs_departureInformation_airport_code'
 - 'flightLegs_season'
 - 'flightLegs_arrivalInformation_times_scheduled_dayPeriod'
 - 'flightLegs_departureInformation_times_scheduled_dayPeriod'
 - Numériques
 - 'flightLegs_scheduledFlightDuration'

Hyperparameter tuning

- GridSearchCV (petit nombre de paramètres pour tester la pipeline)
- cv = 5
- scoring = accuracy


Algorithmes

- Logistic_OVO (One vs One)
 - {'classifier__estimator__C': [0.01, 0.1, 1], 'classifier__estimator__penalty': ['l2']}
 - best score: 0.78 | Total duration: 24 seconds
- Logistic_OVR (One vs Rest)

- {'classifier__estimator__C': [0.01, 0.1, 1], 'classifier__estimator__penalty': ['l2']}
- best score: 0.78 | Total duration: 35 seconds
- DecisionTree
 - {'classifier__max_depth': [2, 3], 'classifier__criterion': ['gini', 'entropy']}
 - best score: 0.71 | Total duration: 9 seconds
- RandomForest
 - {'classifier__n_estimators': [50, 100]}
 - best score: 0.84 | Total duration: 1596 seconds -> très lent

Exemple de Matrice de confusion

RandomForest



Conclusion

Accuracy plutôt bonne (84%) pour late/on_time, mais mauvaise pour cancelled.

Régression

Séparation jeux de données

- Vols avec flightLegs_irregularity_delayDuration_total > 0
- entraînement 80% 140176 vols
- test 20% 35045 vols

Type de données

- Valeur cible : flightLegs_irregularity_delayDuration_total
- Valeurs explicatives
 - Catégorielles
 - 'flightLegs_aircraft_typeCode'
 - 'flightLegs_arrivalInformation_airport_code'
 - 'flightLegs_departureInformation_airport_code'
 - 'flightLegs_season'
 - 'flightLegs_arrivalInformation_times_scheduled_dayPeriod'
 - 'flightLegs_departureInformation_times_scheduled_dayPeriod'
 - Numériques
 - 'flightLegs_scheduledFlightDuration'

Hyperparameter tuning

- GridSearchCV (petit nombre de paramètres pour tester la pipeline)
- cv = 5
- scoring = r²

Algorithmes

- LinearRegression
 - score: 0.02 | Total duration: 4 seconds
- XGBRegressor
 - {'classifier__n_estimators': [50, 100], 'classifier__max_depth': [3, 5]}
 - best score: 0.05 | Total duration: 35 seconds
- DecisionTreeRegressor
 - {'classifier__max_depth': [3, 5, 7]}
 - best score: 0.03 | Total duration: 2 seconds
- RandomForestRegressor
 - {'classifier__n_estimators': [50, 100]}
 - best score: -0.02 | Total duration: 1596 seconds -> Très lent

Conclusion

Algorithmes de régression très mauvais sur ce jeu de donnée avec ces paramètres.

Pistes à creuser :

- Transformation de la variable cible si relations non linéaires avec les variables explicatives
- gestion des valeurs extrêmes
- autres algorithmes de machine learning
- Ajout/suppression de variables explicatives
- Hyperparameter tuning plus poussé