

Analyse des algorithmes de prédiction

Tableau comparatif - algorithmes de prédiction de retards de vol

Algorithme	Avantages	Inconvénients	Adaptation à notre projet
Régression linéaire	Simple à comprendre et rapide à appliquer. Permet d'estimer un retard (ex : plus de 10 minutes).	Suppose que les variables influencent le retard de façon proportionnelle (si un facteur augmente, le retard augmente régulièrement).	Peut servir pour estimer un retard en minutes mais devient limité si plusieurs facteurs interagissent (météo, aéroport, horaire...).
Régression logistique	Prédit si un vol sera en retard (Oui/Non). Donne une probabilité claire de retard (ex : 70 % de chance de retard).	Ne donne pas la durée du retard. Moins efficace si plusieurs causes se combinent.	Idéale comme premier modèle de référence pour distinguer vol à l'heure / vol en retard.
Arbres de décision / Random Forest	Fonctionne avec des données venant de sources différentes (API, SQL...). Gère les valeurs manquantes ou incohérentes.	Difficile d'expliquer précisément comment la décision est prise (modèle moins interprétable).	Très adapté car nos données peuvent être incomplètes ou variées. Bon équilibre entre fiabilité et facilité d'utilisation.
Gradient Boosting / XGBoost	Très performant pour détecter des combinaisons de facteurs (ex : retard selon aéroport + météo + heure).	Plus long à entraîner. Nécessite des réglages plus précis.	Excellent candidat final si l'objectif est d'obtenir la meilleure précision.
Réseaux de neurones (ANN)	Capables de détecter des relations très complexes entre plusieurs facteurs (ex : météo + saturation + type avion).	Recquiert beaucoup de données et de temps de calcul pour apprendre. Les prédictions peuvent être difficiles à interpréter.	À envisager uniquement si on a un grand volume de données historiques.
Modèles temporels (Prophet, LSTM)	Permettent de prédire l'évolution d'un retard au fil du temps (ex : retard estimé +10min → +18min → +25min).	Pas adaptés car notre but n'est pas de suivre un retard, mais de prédire s'il y aura retard ou non.	Non retenus.

Synthèse des recommandations

Algorithme	Justification
Régression logistique	Fournit une probabilité de retard (Oui/Non). Facile à interpréter. Sert de base de comparaison.
Random Forest	Fiable même si certaines données sont manquantes. Gère bien les données variées (API + SQL).
XGBoost	Offre la meilleure précision si on cherche à optimiser les résultats.

À la suite de notre analyse, trois algorithmes ressortent comme les meilleures options possibles pour prédire les retards de vol :

- Régression logistique : elle permet de prédire clairement si un vol sera en retard ou non, avec une probabilité facile à interpréter.
- Random Forest : ce modèle est plus robuste et peut utiliser différents types de données, même si certaines sont manquantes ou proviennent de sources différentes (API, base SQL...).
- XGBoost : il offre généralement la meilleure précision car il est capable d'apprendre des situations où plusieurs facteurs combinés (comme l'aéroport, l'horaire et la météo) augmentent ensemble le risque de retard.

Sources

Source / Référence	Lien web
Scikit-learn - Régression linéaire	https://scikit-learn.org/stable/modules/linear_model.html#ordinary-least-squares
Scikit-learn - Régression logistique	https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
Scikit-learn - Arbre de décision / Random Forest	https://scikit-learn.org/stable/modules/ensemble.html#random-forests
Scikit-learn - Gradient Boosting (base de XGBoost)	https://scikit-learn.org/stable/modules/ensemble.html#gradient-boosting
Documentation officielle XGBoost	https://xgboost.readthedocs.io/
DataCorner – XGBoost expliqué simplement	https://datacorner.fr/xgboost/
TensorFlow – Réseaux de neurones (ANN)	https://www.tensorflow.org/tutorials/keras/classification
Kaggle – Notebook “Flight Delay Prediction using XGBoost”	https://www.kaggle.com/code/luiscrmartins/flight-delay-prediction-using-xgboost
Datacamp – Prédiction avec LSTM	https://www.datacamp.com/fr/tutorial/lstm-python-stock-market

Prophet – Guide indépendant (modèle temporel)	https://datascientest.com/facebook-prophet-tout-savoir
--	---